Pandas

Краткий план

1. Познакомиться с понятием DataFrame объекта в Pandas
2. Попробовать работу с Pandas в консоли

    a. Откройте jupyter-тетрадь (notebook) и работайте в ней параллельно со слайдами
3. Практический урок в **Jupyter-тетради**

Что такое Pandas?

- Библиотека **структур данных** и инструментов для **анализа данных**:
  - Excel на Python
- Базовые объекты для работы с данными – это numpy-массивы
- Обратите внимание: если вы пользуетесь **популярной** библиотекой с большой базой пользователей (как например numpy), и у вас есть вопрос – **ответ на него скорее всего уже есть** на **StackOverflow**!
- **Документация** по Pandas отлично написана (на английском языке)
  - https://pandas.pydata.org/pandas-docs/stable/10min.html

«Анатомия» объекта DataFrame в Pandas

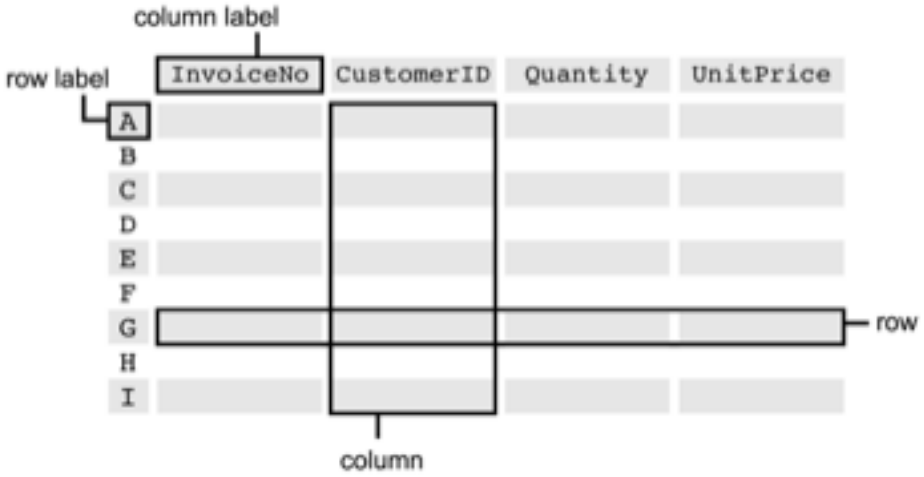

Практическое введение

Откройте jupyter-тетрадь…

```
$ import pandas as pd
$ data = {'name': ['alina', 'oleg'], 'age': [23, 32]}
$ df = pd.DataFrame(data)
$ df
```

```
>   name    age
0   alina   23
1   oleg    32
```

Что такое DataFrame?

```
$ df.values

> array([['alina', 23],
         ['oleg',  32]], dtype=object)

$ df.dtypes

$ df.columns

$ df.index

$ df.index = ['first', 'second']

$ df

>         name  age
first    alina 23
second   oleg  32
```

Индексация и выборка

```
$ df['name'] # или df.name
$ df.loc['second', 'age']
$ df.iloc[1, 1]
$ df.query('age < 30') > name age first alina 23
```

Чтение из CSV-файла

```
$ loc = 'data/your_data.csv'
$ pd.read_csv(loc)
```

Можно читать с web-сайтов!

Другие аргументы, например header (шапка), позволяют настроить импорт: обращаться к колонкам по имени и выбрать колонку, по которой будет проходить индексация.

```
$ url = 'https://goo.gl/XE5CrW'
$ pd.read_csv(url, header=None)
```

Прочтите документацию!

Полезные функции, методы и атрибуты

```
$ pd.isnull(df)
$ df.fillna(value=0)
$ df.describe()
$ df.plot()
$ df.reset_index()
$ df.set_index('name')
$ df.index
$ df.values # Симба, не забывай, кто ты...
$ df.col.unique() # а также математические функции вроде df.col.max()
$ df.groupby(...)
```

Практическое занятие

01-pandas-skeleton-rus.ipynb

20 минут